



INFORME TRABAJO PRÁCTICO CUATRIMESTRAL

Procesamiento de Imágenes Biomédicas

“Detección, segmentación y ubicación de glioblastomas en Resonancia Magnética Nuclear”

Grupo 1

Di Pasquale Santino (62793)

Salvatore Renato (64924)

Vallejos Ludmila (63077)

Fecha de entrega: 10/06/2026

ÍNDICE

INTRODUCCIÓN.....	1
MATERIALES Y MÉTODOS.....	1
1. Preprocesamiento.....	2
2. Segmentación y detección.....	2
3. Ubicación anatómica.....	3
4. Interfaz Gráfica.....	4
RESULTADOS.....	5
1. Preprocesamiento.....	5
2. Segmentación del cráneo.....	5
3. Segmentación del tumor.....	6
CONCLUSIÓN.....	7

INTRODUCCIÓN

El glioblastoma es el tumor cerebral primario maligno más frecuente y agresivo en adultos, obteniendo el mayor grado de calificación de malignidad según la OMS [3]. Este cuenta con una estructura interna muy heterogénea, donde en su interior se encuentra tejido necrosado y en su borde se encuentran células tumorales activas, las cuales son, en este caso, astrocitos (Imagen 1).




Imagen 1. Paciente con glioblastoma en región gancho sigmoideo.

La Resonancia Magnética Nuclear (RMN) es el método *gold standard* para el diagnóstico de esta enfermedad y hoy en día existen múltiples modelos de deep learning, como GBT-SAM y Dense Unet+ [4], los cuales tienen la capacidad de asistir en el manejo de esta enfermedad pudiendo segmentar tanto al tumor del cerebro como su estructura interna.

En el presente trabajo se desarrolló un algoritmo, el cual permite detectar, segmentar y ubicar en el cerebro lesiones de glioblastoma en estudios de RMN.

MATERIALES Y MÉTODOS

Para llevar a cabo el objetivo propuesto se empleó el dataset de OpenNeuro ds007045. Éste cuenta con múltiples RMN de diferentes pacientes con glioblastoma en ventanas T1 pre y post-contraste, T2 y FLAIR. Se utilizaron únicamente las imágenes obtenidas en ventana T1 post-contraste dado que, al estar dañada la barrera hematoencefálica en esta enfermedad, el contraste se acumula en esta región facilitando la detección del tumor.

Por otro lado, se hizo uso de distintos atlas anatómicos para lograr la ubicación del tumor en el cerebro del paciente posterior a su correcta detección y segmentación. Para regiones corticales se empleó el atlas Destrieux 2009, el cual cuenta con 148 regiones corticales, mientras que para regiones subcorticales se utilizó el atlas subcortical de Harvard - Oxford.

El pipeline implementado por el algoritmo desarrollado (Imagen 2) cuenta con una etapa de **preprocesamiento**, una etapa de **segmentación y detección** y otra de **ubicación anatómica**, las cuales serán detalladas a continuación.




Imagen 2. Pipeline implementado por el algoritmo.

1. Preprocesamiento

Un escáner de resonancia magnética adquiere datos en forma de señales complejas compuestas por dos canales independientes: un canal real y otro imaginario. Ambos canales contienen la señal verdadera del tejido más ruido térmico generado por el movimiento aleatorio de electrones en las bobinas receptoras y en el propio paciente. Los detectores del resonador magnético registran las señales de radiofrecuencia emitidas por los protones de hidrógeno del cuerpo humano (previamente alineados por el campo magnético principal del escáner y excitados por pulsos magnéticos) al relajarse hacia su estado de equilibrio. El instrumento descompone las señales registradas en sus componentes de fase y en cuadratura.

Sin embargo, no se trabaja con éstas señales originales complejas, sino con imágenes de magnitud. Esta operación de transformación tiene una consecuencia estadística significativa, ya que el ruido en los canales originales en la imagen de magnitud que era gaussiano simétrico pasa a adoptar una distribución asimétrica descrita por la distribución de Rice [1], obteniéndose así el ruido Rician característico de RMN. Es por esto que modelos como el filtro gaussiano o de mediana resultan inadecuados para aislar el ruido Rician y resulta necesario aplicar filtros avanzados.

Al realizar un análisis del ruido presente en las imágenes mediante la visualización de sus histogramas (Imagen 3), excluyendo valores mínimos correspondientes al fondo negro de la imagen, se obtuvo una curva que difería a curvas características de ruidos estudiados previamente (Gaussiano, impulsivo, entre otros) pero mantenía similitudes con una curva de ruido Speckle. Aún así, un filtro que normalmente trataría con el ruido Speckle resultó muy destructivo para las imágenes trabajadas, corroborando lo esperado en base a la naturaleza del ruido Rician.




Imagen 3. Ejemplo de histograma de un corte.

Particularmente se utilizó el filtro de difusión Perona-Malik (también llamado filtro de Difusión Anisotrópica) [2]. Este filtro tiene como objetivo la reducción de ruido sin costo de calidad de imagen. Además tiene la característica de difundir la imagen dentro de regiones, priorizando la preservación de bordes.

2. Segmentación y detección

Para lograr la correcta segmentación del tumor, primero se segmenta el cerebro del paciente separándolo del cráneo. Empleando el método Otsu se halló el umbral, el cual permite separar ambas estructuras. Este método es muy efectivo cuando, entre el cráneo y

el cerebro, hay una gran región hipointensa. Este no era el caso en la mayoría de los cortes, ya que quedaban segmentos que unían ambas regiones, dificultando la creación de la máscara. Por esta razón, a la imagen binaria inicial obtenida mediante Otsu se le aplicaron operaciones morfológicas con el fin de poder eliminar los segmentos “puente” entre ambas estructuras. Primero se realizó una erosión sobre esta imagen y luego una dilatación para recuperar parte de las estructuras reducidas por la erosión.

Se requiere trabajar únicamente con la máscara del cerebro y poder identificarla fácilmente, por lo que se etiquetaron las regiones obtenidas y se clasificaron según su propiedades mediante el uso de la librería scikit-image (`skimage.measure.regionprops`). Para el etiquetado se estableció que un elemento es vecino de otro si comparten un lado o una esquina, obteniendo así un criterio más permisivo dado que la estructura del cerebro puede ser irregular en los bordes. Para clasificar las etiquetas, se utilizó la propiedad **solidez** de `regionprops` la cual se calcula como:

$$\text{solidez} = \frac{\text{área de la región}}{\text{área del convex hull}} \quad \text{Ecuación 1}$$

El convex hull es un polígono que contiene a toda la región, midiendo el área total que ocuparía esa región si estuviese completa. De esta forma, la solidez tiene valores entre 0 y 1, siendo valores cercanos a 1 regiones muy llenas y valores cercanos a 0 regiones muy huecas. Debido a que la región del cráneo tiene forma de anillo (al visualizar un corte), su solidez es muy baja; aprovechando esta característica, se etiqueta al cráneo como la zona con menor valor de solidez. Al excluir esta etiqueta y preservar las otras, se obtiene finalmente la máscara correspondiente al cerebro, logrando así la segmentación del mismo.

Se procedió a segmentar el tumor. Para obtener un resultado óptimo, primeramente se aumentó el contraste tumor-imagen empleando un algoritmo con los siguientes pasos: se tomó un recorte de una esquina de la imagen (cerciorando que éste no contenga anatomía y sólo presente ruido de fondo); se estimó el valor de sigma con la fórmula (Ecuación 2) de distribución de Rician:

$$\sigma = \frac{\mu_{\text{fondo}}}{\sqrt{\pi/2}} \quad \text{Ecuación 2}$$

Se elevó cada píxel a la cuarta potencia para amplificar las diferencias de intensidad, pues valores altos crecen considerablemente más que los bajos, y se le restó el valor de sigma estimado para compensar el sesgo introducido por la distribución Rician. Se forzó a 0 cualquier valor negativo, es decir, zonas puramente ruidosas, y luego se aplicó la raíz cuadrada con el fin de suavizar levemente el realce, otorgando como producto la imagen con el contraste aumentado.

Posterior al aumento del contraste y realce del borde del tumor se utilizó Multi Otsu para obtener el nuevo umbral: al no estar presente el cráneo, las regiones del cerebro tienen niveles de intensidad similar y el método de Otsu simple resulta inefectivo. Con Multi Otsu se obtuvo la máscara del tumor y se le aplicó `fill_holes` (de la librería `scipy`) para que esté completa en el centro y no se pierda información.

Al realizar pruebas en múltiples cortes, se observó que este enfoque es muy efectivo en cortes donde el tumor está presente, pero falla en aquellos donde no hay lesión: la segmentación detectó estructuras anatómicas con suficiente contraste. Con el objetivo de eliminar estos “falsos positivos”, se realizó un análisis de texturas, empleando la homogeneidad para clasificar y eliminar las máscaras de regiones no tumorales: dado que las lesiones presentan heterogeneidad, su homogeneidad es generalmente menor que el resto del cerebro.

El análisis de estructuras requiere de la obtención de la matriz GLCM. Dado que la imagen tiene 256 niveles de intensidad, la matriz resulta de 256 x 256, por esta razón se hizo un *downsampling* disminuyendo a 16 los valores de intensidad. El análisis de los parámetros se realizó en 4 direcciones y los resultados fueron promediados para evitar la preponderancia de una dirección. Empíricamente, luego de múltiples pruebas sobre el tumor y otras regiones del cerebro, se determinó una cota superior e inferior de homogeneidad: sólo aquellas regiones (segmentadas en la última instancia) con valores de homogeneidad entre 0.56 y 0.68 serán consideradas tumor.

3. Ubicación anatómica

Una vez detectado el tumor, se obtuvo su centroide en coordenadas de voxel del paciente (fila_tumor, columna_tumor, numero_de_corte) a partir de regionprops sobre la máscara segmentada. El objetivo es traducir esas coordenadas a una etiqueta anatómica legible.

Proyección al espacio del atlas: cada volumen NIfTI contiene una matriz afín (*affine*) que mapea coordenadas de voxel al espacio físico del escáner. El atlas también tiene su propia transformación afín. La proyección se realiza en dos pasos:

- voxel_tumor_MNI = affine_paciente @ [fila, columna, corte, 1]
- voxel_tumor_MNI = inv(affine_atlas) @ voxel_tumor_MNI

Esto transforma el centroide del tumor primero al espacio físico del escáner y luego al espacio de voxels del atlas, permitiendo consultar qué etiqueta anatómica corresponde a esa posición.

Atlas en cascada: se utilizó primero el atlas de Harvard-Oxford subcortical (sub-maxprob-trh25-2mm), que cubre estructuras profundas como tálamo, núcleo caudado, putamen y otros ganglios basales. Si el resultado es "Background" - es decir, la región no está cubierta por el atlas subcortical, lo que ocurre típicamente para tumores corticales - se consulta en cascada el atlas cortical de Destrieux (2009), que cubre la corteza cerebral con mayor granularidad. Si tampoco lo indexa, se reporta "Región no indexada por el atlas". En caso de que no haya tumores detectados, la función retorna directamente "No se detectaron tumores" sin realizar ninguna consulta al atlas.

Limitación conocida: la transformación afín de los volúmenes del dataset mapea el espacio del escáner y no al espacio estándar MNI. Esto introduce un error de proyección cuya magnitud depende de cuánto difiere la orientación y escala del volumen del paciente respecto del atlas. Esta limitación se asume como una simplificación del pipeline y se documenta como una mejora futura prioritaria, que requeriría un paso de registro no lineal al espacio MNI previo a la consulta del atlas.

4. Interfaz Gráfica

La interfaz (Imagen 4) se desarrolló con PySide6, framework de Qt para Python, que permite construir aplicaciones de escritorio con widgets nativos. Se optó por esta herramienta dado que el pipeline procesa volúmenes NIfTI corte a corte, lo que requería una forma de navegar interactivamente por el eje axial sin tener que re-ejecutar el script manualmente para cada corte.

La clase principal MyWidget hereda de QWidget y recibe como parámetro la función procesar, desacoplando completamente la lógica de procesamiento de la capa visual. El

layout se organiza en dos niveles: un QHBoxLayout que contiene el visor de imagen (QLabel) y el panel de localización (QTextEdit de solo lectura), ambos dentro de un QVBoxLayout principal junto al botón de carga y el slider.

La navegación entre cortes se implementa con un QSlider horizontal conectado mediante señal-slot (valueChanged) al método update_slice, que ante cada cambio extrae el corte correspondiente del volumen, llama al pipeline y actualiza la imagen y el texto de localización. De esta forma, el procesamiento se dispara de forma reactiva ante la interacción del usuario sin necesidad de bucles de polling. La imagen se convierte a QImage en formato RGB888 y se escala manteniendo la relación de aspecto antes de mostrarse, aplicando además una rotación de 90° para corregir la orientación de los arrays NIfTI respecto de la convención de visualización.




Imagen 4. Interfaz.

RESULTADOS

1. Preprocesamiento

En primer lugar, se aplicó el filtro anisotrópico a cada frame que iba a ser analizado.




Imagen 5. Frame Paciente pos-procesamiento.

2. Segmentación del cráneo

Se encontró el umbral mediante Otsu para segmentar el cráneo. Aplicando este umbral se obtuvo el siguiente resultado:




Imagen 6. Frame original (izquierda) e imagen binarizada (derecha)

Luego, se aplicó erosión y closing para eliminar los segmentos que unen al cerebro con el cráneo y, eliminando la etiqueta cuya solidez es la mínima, se obtuvieron todas las regiones correspondientes al cerebro:




Imagen 7. Resultado obtenido al aplicar operaciones morfológicas.

Finalmente, se empleó *fill_holes*, rellenando el interior de la máscara para preservar lo más posible la estructura interna del cerebro. De esta forma, multiplicando esta máscara elemento a elemento por la imagen original del corte, se segmentó correctamente el cerebro del paciente:




Imagen 8. Máscara del cerebro (izquierda) y cerebro segmentado (derecha).

3. Segmentación del tumor

Para segmentar el tumor en los cortes donde este estaba presente, se aumentó el contraste con el método detallado:




Imagen 9. Resultado del aumento de contraste.

Con Multi Otsu se halló el umbral correspondiente al borde hiperintenso de la lesión y se creó la imagen binaria. Aplicando a la misma fill holes, se preservó la estructura interna del tumor.




Imagen 10. Máscara del tumor pre (izquierda) y post (derecha) operaciones morfológicas.

Luego de analizar la homogeneidad únicamente de la región segmentada por la máscara hallada y desechando los resultados fuera por este, se obtuvo el tumor segmentado.




Imagen 11. Resultado final: segmentación del tumor.

CONCLUSIÓN

El pipeline desarrollado logró detectar, segmentar y localizar anatómicamente lesiones de glioblastoma en imágenes de RMN T1 post-contraste de forma automática. La combinación de filtrado anisotrópico, umbralización de Otsu y realce de contraste con corrección de sesgo Rician demostró ser efectiva para el procesamiento, preservando los bordes del tumor sin destruir estructuras anatómicas relevantes. La segmentación del cráneo mediante solidez de componentes conexas resultó más robusta que un simple criterio de área, ya que el cráneo tiene una morfología de anillo con solidez característicamente baja independientemente del corte analizado. La validación por homogeneidad GLCM fue clave para eliminar falsos positivos en cortes sin tumor, siendo el rango 0.56-0.68 un criterio empírico que refleja la heterogeneidad propia del glioblastoma respecto al parénquima sano.

Como limitaciones principales se identificaron dos. Por un lado, la proyección al atlas se realiza a través de la transformación afín del escáner y no mediante registro al espacio MNI, lo que introduce un error de localización cuya magnitud es variable entre pacientes. Por otro lado, el criterio de homogeneidad fue calibrado sobre los pacientes del dataset ds007045 y no puede generalizarse a otras poblaciones o protocolos de adquisición sin reajuste de los umbrales.

Como mejoras futuras se propone implementar un paso de registro no lineal al espacio MNI previo a la consulta del atlas, incorporar las modalidades T2 y FLAIR para enriquecer la segmentación con información multispectral, y evaluar el pipeline con métricas cuantitativas estándar del campo (*Dice score*, sensibilidad, especificidad) comparando contra las segmentaciones manuales disponibles en el dataset, lo que permitirá un posicionamiento objetivo respecto a los métodos de *deep learning* del estado del arte como GBT-SAM y Dense UNet+.

BIBLIOGRAFÍA

[1] H. Gudbjartsson and S. Patz, "The Rician distribution of noisy MRI data," *Magnetic Resonance in Medicine*, vol. 34, no. 6, pp. 910–914, 1995. DOI: 10.1002/mrm.1910340618

[2] loli, "medpy: Medical image processing in Python — anisotropic diffusion notebook," GitHub. [Online]. Available: https://github.com/loli/medpy/blob/master/notebooks/scripts/medpy_anisotropic_diffusion.py.ipynb. [Accessed: Jun. 10, 2026]

[3] A. F. Tamimi and M. Juweid, "Epidemiology and Outcome of Glioblastoma," in *Glioblastoma*, S. De Vleeschouwer, Ed. Brisbane: Codon Publications, 2017. [Online]. Available: <https://www.ncbi.nlm.nih.gov/books/NBK470003/>

[4] C. Diana-Albelda, Á. García-Martín, and J. Bescos, "A Review on Deep Learning Methods for Glioma Segmentation, Limitations, and Future Perspectives," *J. Imaging*, vol. 11, no. 8, p. 269, Aug. 2025. DOI: 10.3390/jimaging11080269